

國立陽明交通大學  
資訊管理與財務金融學系財務金融碩士班  
碩士論文

Graduate Program of Finance  
National Yang Ming Chiao Tung University  
Master Thesis

基於圖神經網絡的股票收益預測與選股策略—融合市  
場結構的多因子模型  
Stock Return Prediction and Selection via Graph Neural  
Networks: Integrating Market Structure into a Multi-Factor  
Model

研 究 生：羅頤 (Lo, Yi)

指導教授：黃宜侯 (Huang, Alex YiHou)

中華民國 一一五年六月

June 2026

基於圖神經網絡的股票收益預測與選股策略—融合市場結構的多因  
子模型

Stock Return Prediction and Selection via Graph Neural Networks:  
Integrating Market Structure into a Multi-Factor Model

研 究 生：羅頤

Student：Yi Lo

指導教授：黃宜侯 博士

Advisor：Dr. Alex YiHou Huang



June 2026

Taiwan, Republic of China

中華民國 一一五年六月

# 誌 謝

謝天謝地，感謝國立陽明交通大學提供良好的研究環境與資源，使我能順利完成學業。

羅頤 謹誌

國立陽明交通大學 資訊管理與財務金融學系財務金融碩士班

中華民國 一一五年六月



# 基於圖神經網絡的股票收益預測與選股策略—融合市場結構的多因子模型

學生：羅頤

指導教授：黃宜侯 博士

國立陽明交通大學  
資訊管理與財務金融學系財務金融碩士班

## 摘 要

中文摘要就從這邊開始寫。

本研究採用圖注意力網絡 (GAT) 和動態多因子模型 (DMFM)，利用產業圖和全市場圖的結構特性進行個股收益率預測，並通過動態投資組合回測評估模型的實際投資績效。

**關鍵字：**圖注意力網絡、股票收益率預測、量化投資策略

# **Stock Return Prediction and Selection via Graph Neural Networks: Integrating Market Structure into a Multi-Factor Model**

Student : Yi Lo

Advisor: Dr. Alex YiHou Huang

Graduate Program of Finance  
National Yang Ming Chiao Tung University

## **Abstract**

Write your English abstract here. This research employs Graph Attention Networks (GAT) and Dynamic Multi-Factor Models (DMFM) to predict individual stock returns using structural characteristics of industry graphs and market-wide graphs, and evaluates the practical investment performance through dynamic portfolio backtesting.

**Keywords:** Graph Attention Network, Stock Return Prediction, Quantitative Investment Strategy.

# 目錄

中文摘要.....	i
英文摘要.....	ii
目錄.....	iii
圖目錄.....	vi
表目錄.....	vii
第一章 緒論.....	1
1.1 研究背景.....	1
1.2 研究問題.....	1
1.3 研究方法與貢獻.....	1
1.4 論文架構.....	1
第二章 文獻回顧.....	3
2.1 技術指標與特徵工程.....	3
2.2 LSTM/RNN 方法 .....	4
2.3 圖神經網路基礎.....	5
2.4 GAT 在股票預測的應用.....	6

第三章 實驗設計.....	8
3.1 資料來源與預處理.....	8
3.1.1 資料來源.....	8
3.1.2 資料預處理.....	9
3.1.3 資料集劃分.....	10
3.2 特徵工程與圖結構.....	10
3.2.1 特徵選取與分類.....	10
3.2.2 圖結構設計與建構流程.....	11
3.3 模型設計.....	11
3.3.1 LSTM 基準模型.....	11
3.3.2 DMFM 模型架構 (Wei et al. 2022) .....	12
3.4 損失函數.....	13
3.4.1 總損失函數.....	13
3.5 評估指標.....	13
3.5.1 預測準確度指標.....	13
3.5.2 投資組合績效指標.....	14
3.5.3 基準比較.....	14
3.5.4 評估流程.....	14
第四章 實驗結果.....	16
4.1 模型對比.....	16
4.2 投組績效驗證.....	16

4.3 特徵重要性排名.....	16
第五章 結論.....	17
5.1 主要發現.....	17
5.2 與既有研究的對比.....	17
5.3 模型限制.....	17
5.4 實踐應用與未來方向.....	17
參考文獻.....	18





# 圖目錄



# 表目錄



# 第一章、緒論

## 1.1 研究背景

(此處撰寫研究背景內容)

## 1.2 研究問題

(此處撰寫研究問題內容)

## 1.3 研究方法與貢獻

(此處撰寫研究方法與貢獻內容)

## 1.4 論文架構

本論文共分為五章，各章內容如下：

第一章為緒論，說明研究背景、研究問題、研究方法與貢獻，以及論文架構。

第二章為文獻回顧，探討技術指標與特徵工程、LSTM/RNN 方法、圖神經網路基礎，以及 GAT 在股票預測的應用。

第三章為實驗設計，介紹資料來源與預處理、特徵工程與圖結構、模型設計（包含 LSTM、GAT、DMFM 模型）、損失函數，以及評估指標。

第四章為實驗結果，呈現模型對比、投組績效驗證，以及特徵重要性排名。

第五章為結論，總結主要發現、與既有研究的對比、模型限制，以及實踐應用與未來方向。



## 第二章、文獻回顧

### 2.1 技術指標與特徵工程

技術指標在股票預測領域扮演重要角色，透過分析歷史價格與成交量資料來預測未來股價走勢。常見的技術指標包括移動平均線（Moving Averages, MA）、相對強弱指標（Relative Strength Index, RSI）、平滑異同移動平均線（Moving Average Convergence Divergence, MACD）以及能量潮指標（On-Balance Volume, OBV）等，這些指標分別用於捕捉市場趨勢、動能以及市場強度，對投資決策具有關鍵影響 [?, ?]。

技術分析的核心在於整合多個指標以建立全面性的預測模型。實證研究顯示，結合多個技術指標的預測能力顯著優於單一指標 [?, ?]。這種多指標整合的方法能夠從不同角度捕捉市場訊號，提升預測的穩健性與準確度。

近年來，深度學習技術的興起為技術指標的應用帶來新的突破。長短期記憶網路（Long Short-Term Memory, LSTM）等深度學習模型被廣泛應用於分析技術指標所產生的時間序列資料 [?, ?]。LSTM 網路特別擅長捕捉資料中的長期依賴關係，使其適合處理股價的高度波動性。綜合分析指出，將深度學習技術與多個技術指標結合，可以顯著提升預測效能，其準確率能夠超越傳統基準 [?, ?]。

此外，機器學習在技術指標參數優化方面也展現出顯著成效。Aguirre 等人證明，將遺傳演算法（Genetic Algorithms）應用於 MACD 指標的參數調整，能夠產生在各種市場條件下顯著優於傳統技術分析的投資策略 [?]。這表明機器學習不僅能改善交易策略的參數設定，還能增強其對市場動態變化的適應能力。

在投資組合管理方面，結合基本面分析與技術分析的混合模型已成為主流趨勢。

Ouazzane 等人提出整合機器學習、財務比率與技術指標的混合模型，專門針對 Nasdaq 半導體市場進行投資組合優化，證明了機器學習在整合不同分析方法以建立穩健交易策略的有效性 [?]。

情緒分析的整合也逐漸受到重視。將財經新聞的市場情緒納入預測模型，已被證明能夠提升股價預測的準確性，提供純粹技術指標可能忽略的額外市場脈絡 [?, ?]。這顯示出混合模型的趨勢，即融合傳統技術分析、機器學習演算法與情緒分析，以建立更為穩健的預測框架。

綜上所述，將技術指標整合於先進的計算框架（如深度學習模型）中，為股價預測提供了有力的方法。多個互補指標的結合提升了預測準確性，而情緒分析的納入則引入了能夠影響市場行為與決策的重要維度。這種多面向的分析強調了對技術指標與新興機器學習方法的深入理解，對於在動態的股票市場預測領域中取得成功至關重要。

## 2.2 LSTM/RNN 方法

長短期記憶網路（Long Short-Term Memory, LSTM）因其處理金融時間序列資料中複雜時間依賴關係的能力，在股票報酬率預測領域獲得廣泛關注。研究指出，LSTM 的內在架構能有效建模非線性金融資料，使其相較於傳統模型具有顯著優勢 [?]。LSTM 網路在處理股票市場指數的非線性特徵方面表現優異，其成功源於能夠從大量輸入維度中學習，而無需進行大量的特徵降維處理 [?]。

近期研究強調整合額外預測因子（如市場情緒）的重要性。Wang 等人證明，將情緒分析整合至 LSTM 模型能顯著提升預測準確性，他們利用 Granger 因果檢定建立情緒指數與股票報酬率之間的關聯 [?]。Yan 等人進一步證實，當 LSTM 模型結合多種資料來源（包括新聞情緒）時，預測效能表現優異 [?]。這表明豐富 LSTM 的輸入資料能夠改善預測效能，強調了在此類模型中建立全面特徵集的必要性 [?]。

對傳統 LSTM 架構的改良也成功提升了預測能力。Peng 與 Guo 在 LSTM 網路中引

入結構變化，包括調整層數與神經元配置，這些改良提高了中國銀行股票的預測精度 [?]。同樣地，將 LSTM 與其他演算法結合的技術——如粒子群最佳化（Particle Swarm Optimization）以及 GARCH-LSTM 等混合模型——已被證明能有效處理資料波動並增強預測能力 [?]。這些混合模型凸顯了 LSTM 作為推進股票預測方法論基礎要素的多樣性。

特徵工程技術如主成分分析（Principal Component Analysis, PCA）也被證明能提升 LSTM 的效能。PCA 有助於解決維度問題，同時保留資料的關鍵特徵 [?]。將 PCA 與 LSTM 結合，研究者在多個金融市場的預測準確度上取得了顯著進展 [?]。這種方法不僅降低了計算複雜度，還能保持模型對重要市場特徵的敏感性。

此外，LSTM 模型的架構設計也持續演進。研究顯示，透過調整 LSTM 的層數、隱藏單元數量以及 dropout 機制，能夠顯著影響模型的預測表現 [?]。這些架構上的微調使得 LSTM 能夠更好地適應不同市場特性與資料特徵，展現出其作為深度學習模型的靈活性。

綜上所述，LSTM 在股票報酬率預測的應用研究揭示了一個能夠捕捉金融資料中複雜模式與關係的穩健框架。持續的建模技術改良——包括情緒整合、混合架構以及特徵優化——進一步鞏固了 LSTM 作為金融預測關鍵工具的地位。這些進展不僅提升了預測準確性，也為理解金融市場的動態行為提供了更深入的見解。

## 2.3 圖神經網路基礎

圖神經網路（Graph Neural Networks, GNN）以圖為基本資料結構，透過節點與邊的關係刻畫資料之間的依賴性。其核心思想是利用訊息傳遞（message passing）機制，使每個節點在多層聚合鄰居資訊後學習到具備結構語意的表示。相較於傳統向量化特徵，GNN 能直接保留關係拓撲與相互影響，特別適合建模互動性強、關係密集的金融市場資料 [?, ?]。

在眾多 GNN 架構中，圖卷積網路（Graph Convolutional Network, GCN）為代表性方法之一。GCN 將卷積操作推廣至圖結構，透過鄰接矩陣與特徵矩陣的規範化聚合，更新節點嵌入向量 [?]. 此種局部鄰域平均的設計能夠捕捉社群與相似性結構，但也可能因過度平滑（over-smoothing）而降低節點差異性 [?, ?]。

圖注意力網路（Graph Attention Network, GAT）在 GCN 的基礎上引入注意力機制，允許模型對不同鄰居賦予不同權重，進而提升異質關係建模能力 [?]。GAT 的優勢在於能動態學習重要節點與關係，減少手動定義權重的需求，並在噪音邊或非均質圖中展現更佳表現 [?]. 這種可解釋的權重分配特性，使其在金融應用中更容易對關鍵關係進行分析與解釋。

圖結構在金融領域的應用相當廣泛，包括以產業關聯、供應鏈關係、股價共動性或交易行為構建市場圖，進而捕捉市場內部的傳染效應與集體波動 [?, ?]。透過 GNN，研究者能同時整合個股特徵與關係拓撲，提升對市場動態的理解與預測能力，為後續探討 GAT 在股票預測的應用奠定基礎。

## 2.4 GAT 在股票預測的應用

近年來，GAT 被廣泛應用於股票預測，因其能在圖結構中自動學習關係重要性。相關研究指出，以公司間的關聯作為圖結構並結合個股特徵，可有效提升報酬率或價格走勢的預測能力 [?, ?]. 透過注意力權重，模型能辨識對特定股票影響較大的關係節點，強化模型對市場結構性訊號的敏感度 [?].

圖結構的建構方式是影響 GAT 表現的關鍵。常見做法包含以產業分類建立產業圖、以供應鏈或股權關係建立企業網路，亦有研究使用歷史報酬率相關性或價格共動性建構市場圖 [?, ?]. 產業圖能反映基本面驅動的長期關係，而市場圖則可捕捉短期價格動能與系統性風險傳染；兩者各具優勢，並可透過多圖融合或動態圖更新來提升模型泛化能力 [?, ?].



然而，現有方法仍存在限制。首先，靜態圖無法充分反映關係隨時間變化的特性，導致模型對結構突變與市場 regime shift 的敏感性不足 [?]. 其次，部分研究採用單一關係來源，可能忽略多面向影響因素，進而限制注意力機制的表現上限 [?]. 此外，GAT 的多頭注意力雖能提升表徵能力，但在高度稀疏或噪音關係下容易出現注意力分散與過度擬合的風險 [?].

綜合上述，GAT 在股票預測中的價值在於能以可解釋的注意力權重刻畫市場關係，並將個股資訊與結構性訊號共同納入模型。未來改進方向可聚焦於動態圖建模、多來源關係融合與噪音邊抑制機制，以強化模型穩健性與可轉移性。本研究將沿用此脈絡，透過圖注意力機制建構更能反映市場結構的預測框架，並作為後續模型設計的理論基礎。



## 第三章、實驗設計

本章詳細介紹實驗的完整設計，包含資料來源與預處理、特徵工程與圖結構建構、模型架構設計等。實驗旨在驗證 Deep Multi-Factor Model (DMFM) 在台灣股票市場預測的有效性，並與時間序列基準模型進行對比分析。

### 3.1 資料來源與預處理

本研究採用單一日頻股票資料 CSV 檔作為輸入資料，資料包含每日價格與成交資訊，並同時內含產業分類欄位以利建構產業圖。程式支援中英文欄位對照，最少需具備日期、股票代碼與收盤價欄位，其餘欄位（開高低價、成交量/成交值、市值、流通股數、PB/PS 等）作為因子特徵使用。資料期間由參數 `start_date` 與 `end_date` 指定，並以交易日序列為主軸建立時間索引。若資料來源為 TEJ/TSE 等第三方資料庫，請在此節補充實際來源、授權或取得方式。【待補：資料來源、時間區間與股池說明】

#### 3.1.1 資料來源

本研究使用【待補：資料來源名稱】之台灣股票市場日頻資料。資料表至少包含以下欄位：日期、股票代碼、收盤價；其餘可選欄位包含開高低價、成交量、成交值、市值、流通股數、PB/PS 與產業分類欄位（如 TEJ 產業名稱/代碼）。為確保可重現性，程式內已定義中英文欄位映射，當 CSV 欄位名稱不同時仍可正確辨識。

### 3.1.2 資料預處理

資料預處理是確保模型訓練品質的關鍵步驟，本研究採用的預處理流程如演算法 1 所示。

---

**Algorithm 1** 資料預處理流程

---

- 1: 讀取原始股票資料 (OHLCV, 成交量/成交值, 估值指標, 產業分類)
  - 2: 依股票代碼與日期排序, 數值欄位轉為數值型態
  - 3: 計算標籤:  $y_t = \frac{P_{t+k} - P_t}{P_t}$  #  $k$  日未來報酬率
  - 4: 建構產業圖鄰接矩陣  $E_{ind}$
  - 5: 建構全市場圖鄰接矩陣  $E_{uni}$
  - 6: 建立特徵張量  $F^t \in \mathbb{R}^{T \times N \times F}$  與標籤張量  $y^t \in \mathbb{R}^{T \times N}$
  - 7: 以 0 取代特徵中的 NaN/Inf, 標籤 NaN 保留並以 mask 排除
  - 8: 特徵標準化由模型內部的 BatchNorm 完成
- 

**缺失值處理：**本研究不對缺失值進行插補。特徵層面，所有 NaN/Inf 以 0 取代（以保持張量完整性）；標籤層面，NaN 標籤在訓練與評估時以有效樣本 mask 排除，使模型僅學習可觀測資料。此作法可避免以非實際市場資訊填補所造成的估計偏誤。

**特徵標準化：**資料前處理階段不進行截面標準化，特徵保留原始尺度。模型端在輸入層使用 **Batch Normalization** 進行正規化：

$$x_{normalized} = \frac{x - \mu_{batch}}{\sqrt{\sigma_{batch}^2 + \epsilon}} \quad (3.1)$$

其中  $\mu_{batch}$  與  $\sigma_{batch}^2$  為當前 mini-batch 的均值與變異數， $\epsilon$  為數值穩定項（通常設為  $10^{-5}$ ）。

此設計具有以下優勢：

- **動態標準化：**每個 batch 獨立計算統計量，適應市場環境變化
- **訓練穩定性：**BatchNorm 有助於梯度流動，加速收斂
- **正則化效果：**訓練時的 mini-batch 隨機性提供額外正則化

- **等價性:** BatchNorm 在金融時間序列建模中可視為截面標準化的近似

**標籤定義:** 標籤定義為未來  $k$  日報酬率，公式如下:

$$y_t = \frac{P_{t+k} - P_t}{P_t} \quad (3.2)$$

其中  $P_t$  為時間  $t$  的收盤價， $k$  為預測視窗 (預設  $k = 5$ )。此定義屬於 forward return，避免使用當期或過去資料洩漏未來資訊。

### 3.1.3 資料集劃分

本研究採用時間序列切分，避免未來資訊洩漏。資料以時間順序切分為訓練集與測試集，預設比例為 80%:20% (前 80% 為訓練、後 20% 為測試)。訓練過程採用 early stopping，並以測試期 ICIR 作為模型保存依據。若需更嚴謹實驗，可進一步拆出 validation set 以獨立調參。【可選補充】

## 3.2 特徵工程與圖結構

### 3.2.1 特徵選取與分類

本研究特徵涵蓋多種技術面與統計面訊號，主要可分為：

- **報酬與動能特徵:** 1/3/5/10/20 日報酬、短長動能差 (ret10-ret1、ret20-ret1)。
- **趨勢特徵:** 價格相對移動平均 (5/10/20/60 日)、價格相對近 20 日高低點位置。
- **波動與風險特徵:** 5/10/20/60 日報酬標準差、ATR、最大回撤 (20 日)、beta 與特質波動。
- **量能特徵:** 成交量相對均值、上/下漲日平均量。

- **技術指標:** RSI、KD、MACD。
- **統計特徵:** 偏度、峰度、價格 z-score。
- **流動性與估值:** Amihud illiquidity、PB、PS。

上述特徵由單一 CSV 自動衍生，不需額外外部因子資料。

### 3.2.2 圖結構設計與建構流程

**產業圖 (Industry Graph) :** 產業圖以「同產業股票完全連結」為設計原則，將屬於同一產業的股票視為相互連結，並為每檔股票加入自環。此設計能捕捉同產業內的共通訊號與產業影響。

**全市場圖 (Universe Graph) :** 全市場圖採完全圖設計，所有股票相互連結並包含自環，用以表徵跨產業的市場共同因子影響。此設計對應 DMFM 論文中的 Universe-level 關係，能強化市場共同變動的抽取。

**鄰接矩陣表示 :** 圖結構以 PyG 的 `edge_index` 表示，即  $[2, E]$  形式之邊索引。實作上先以鄰接矩陣建立連結，再轉換為邊索引格式，以利 GAT 層使用。

**建構流程 :** 由輸入 CSV 讀取產業欄位（如 TEJ 產業名稱/代碼），依股票代碼分組建立產業圖；若缺少產業欄，則預設所有股票屬於同一產業。全市場圖則依股票清單建立完全圖。圖結構與特徵張量一併存入 artifacts，供模型訓練與評估重複使用。

## 3.3 模型設計

### 3.3.1 LSTM 基準模型

**模型架構 :** 目前程式碼未包含 LSTM 實作。若需保留此節，建議改為「GATRegressor 基準模型」，或自行補上 LSTM baseline。以下提供兩種處理方式：

- 改寫為 GATRegressor 基準：兩層 GAT + 線性輸出，僅使用產業圖。
- 新增 LSTM baseline：以時間序列特徵輸入 LSTM，再用 MLP 輸出預測。

【待選：採用 GATRegressor 或補上 LSTM baseline】

**超參數配置：**若採 GATRegressor 基準，建議使用與 DMFM 相同的 hidden\_dim、heads 與 dropout，以確保可比性；若採 LSTM baseline，則需補充 LSTM 的 hidden size、層數、dropout 與輸出頭設定。【待補：基準模型超參數】

**與 DMFM 的差異：**LSTM 基準僅利用時間序列特徵，不顯式建模股票間關係；DMFM 則透過產業圖與全市場圖進行中性化，並以階層式拼接整合多層語境，因此能同時捕捉個股特徵與結構性訊號。【待補：是否保留 LSTM baseline】

### 3.3.2 DMFM 模型架構 (Wei et al. 2022)

DMFM 以「特徵編碼 → 產業中性化 → 全市場中性化 → 階層式拼接 → 深度因子學習 → 因子注意力」為主要流程。模型在每個交易日  $t$  對股票截面進行運算，輸出每檔股票的預測因子值。

**步驟 1：特徵編碼器：**原始特徵  $F^t$  經過 BatchNorm 進行截面標準化，再以 MLP 編碼為  $C^t$  (hidden\_dim 維度)，作為原始股票語境表示。

**步驟 2：產業中性化：**以產業圖為圖結構進行 GAT 運算，得到產業影響  $H_I^t$ 。產業中性特徵定義為： $C_I^t = C^t - H_I^t$ ，藉此移除產業共通影響。

**步驟 3：全市場中性化：**在產業中性特徵  $C_I^t$  上，再以全市場圖進行 GAT 運算得到  $H_U^t$ 。全市場中性特徵定義為： $C_U^t = C_I^t - H_U^t$ ，用以移除市場共同影響。

**步驟 4：階層式特徵拼接：**將三層特徵拼接形成階層表示： $H^t = [C^t \parallel C_I^t \parallel C_U^t]$ 。此設計保留原始語境與兩層中性化資訊，提升模型表達力。

**步驟 5：深度因子學習：**拼接後的階層特徵輸入 MLP decoder，輸出深度因子  $f^t$  (每檔股票 1 個數值)，作為預測信號。

**步驟 6：因子注意力模組：**模型同時對原始特徵學習注意力權重，計算  $\hat{f}^t = F^t \odot a^t$ ，用以估計「哪些特徵驅動因子輸出」，並作為解釋與監督項。

**超參數配置：**預設配置如下：hidden\_dim=64、heads=2、dropout=0.1、epochs=200、learning rate=1e-4、weight decay=0.01、lambda\_attn=0.1、lambda\_ic=1.0、patience=30。

## 3.4 損失函數

### 3.4.1 總損失函數

本研究使用 DMFM 對應之損失：

$$L = \lambda_{attn} \cdot \|f - \hat{f}\| + \lambda_{IC} \cdot (1 - IC) - \lambda_b \cdot b \quad (3.3)$$

其中  $\|f - \hat{f}\|$  代表注意力估計誤差； $IC$  為資訊係數； $b$  為截面回歸得到的因子收益。程式中  $\lambda_b$  固定為 0.01，以降低因子收益項之不穩定性。

**Information Coefficient (IC)：**IC 以 Pearson correlation 計算，基於每個交易日的截面預測與真實報酬，衡量預測排序的有效性。

**優化器設定：**使用 AdamW 優化器，並加入 weight decay 以抑制過度擬合。

## 3.5 評估指標

### 3.5.1 預測準確度指標

**IC / Daily IC / ICIR：**IC 為整體樣本的 Pearson correlation；Daily IC 為每交易日 IC 的平均值；ICIR 定義為 IC 平均值除以 IC 標準差，用以衡量資訊係數的穩定性。

**產業中性 IC：**【待補：若有計算產業中性 IC，請補充定義與計算方式；若未使用，

可刪此項。】

**方向準確率：**方向準確率定義為預測方向與真實方向一致的比例，用以衡量模型對漲跌方向的掌握程度。

**誤差指標：**以全部測試樣本誤差衡量預測偏差，包含 MSE、RMSE 與 MAE。

### 3.5.2 投資組合績效指標

**年化報酬率：**策略以每次再平衡取預測分數最高的 top\_pct 股票做多，計算該截面平均報酬作為策略報酬，並依再平衡頻率換算年化報酬率。

**Sharpe Ratio：**Sharpe Ratio 定義為平均報酬除以波動後乘上年化因子，用於衡量風險調整後報酬。

**勝率：**勝率為正報酬期間比例，用於衡量策略穩定性。

**最大回撤：**程式中未計算最大回撤，若需納入，可額外補實作或引用後處理結果。【待補：是否加入最大回撤】

### 3.5.3 基準比較

**天真基準：**天真基準設定所有股票預測值為 0，計算 MSE/RMSE/MAE，並與模型結果比較改善幅度。

**台灣 50 ETF 基準：**使用 0050 報酬資料計算 forward- $k$  日報酬，與策略累積報酬比較。

### 3.5.4 評估流程

流程為：

- 載入 artifacts 與模型權重。
- 對訓練期與測試期分別計算預測指標。



- 產生 Daily IC、方向命中率、預測離散度、IC 分佈與累積報酬等視覺化報告。
- 若為 DMFM，另外輸出注意力權重分佈以進行解釋性分析。



## 第四章、實驗結果

### 4.1 模型對比

(此處撰寫模型對比內容)

### 4.2 投組績效驗證

(此處撰寫投組績效驗證內容)

### 4.3 特徵重要性排名

(此處撰寫特徵重要性排名內容)



# 第五章、結論

## 5.1 主要發現

(此處撰寫主要發現內容)

## 5.2 與既有研究的對比

(此處撰寫與既有研究的對比內容)

## 5.3 模型限制

(此處撰寫模型限制內容)

## 5.4 實踐應用與未來方向

(此處撰寫實踐應用與未來方向內容)

## 參考文獻

