

國立陽明交通大學
資訊管理與財務金融學系財務金融碩士班
碩士論文

Graduate Program of Finance
National Yang Ming Chiao Tung University
Master Thesis

基於圖神經網絡的股票收益預測與選股策略—融合市
場結構的多因子模型
Stock Return Prediction and Selection via Graph Neural
Networks: Integrating Market Structure into a Multi-Factor
Model

研 究 生：羅頤 (Lo, Yi)

指導教授：黃宜侯 (Huang, Alex YiHou)

中華民國 一一五年六月

June 2026

基於圖神經網絡的股票收益預測與選股策略—融合市場結構的多因
子模型

Stock Return Prediction and Selection via Graph Neural Networks:
Integrating Market Structure into a Multi-Factor Model

研 究 生：羅頤

Student: Yi Lo

指導教授：黃宜侯 博士

Advisor: Dr. Alex YiHou Huang



June 2026

Taiwan, Republic of China

中華民國 一一五年六月

誌 謝

謝天謝地，感謝國立陽明交通大學提供良好的研究環境與資源，使我能順利完成學業。

羅頤 謹誌

國立陽明交通大學 資訊管理與財務金融學系財務金融碩士班

中華民國 一一五年六月



基於圖神經網絡的股票收益預測與選股策略—融合市場結構的多因子模型

學生：羅頤

指導教授：黃宜侯 博士

國立陽明交通大學
資訊管理與財務金融學系財務金融碩士班

摘 要

中文摘要就從這邊開始寫。

本研究採用圖注意力網絡 (GAT) 和動態多因子模型 (DMFM)，利用產業圖和全市場圖的結構特性進行個股收益率預測，並通過動態投資組合回測評估模型的實際投資績效。

關鍵字：圖注意力網絡、股票收益率預測、量化投資策略

Stock Return Prediction and Selection via Graph Neural Networks: Integrating Market Structure into a Multi-Factor Model

Student : Yi Lo

Advisor: Dr. Alex YiHou Huang

Graduate Program of Finance
National Yang Ming Chiao Tung University

Abstract

Write your English abstract here. This research employs Graph Attention Networks (GAT) and Dynamic Multi-Factor Models (DMFM) to predict individual stock returns using structural characteristics of industry graphs and market-wide graphs, and evaluates the practical investment performance through dynamic portfolio backtesting.

Keywords: Graph Attention Network, Stock Return Prediction, Quantitative Investment Strategy.

目錄

中文摘要.....	i
英文摘要.....	ii
目錄.....	iii
圖目錄.....	iv
表目錄.....	v
第一章 緒論.....	1
1.1 研究背景.....	1
1.2 研究問題.....	1
1.3 研究方法與貢獻.....	1
1.4 論文架構.....	1
第二章 文獻回顧.....	3
2.1 技術指標如何轉化為深度學習可用之特徵表示.....	3
2.2 LSTM 等時間序列模型在金融預測中的典型做法與延伸.....	4
2.3 LSTM 等時間序列模型在金融預測中的典型做法與延伸.....	4
2.4 圖神經網路的基本概念與代表性架構.....	6
2.5 GAT 及其變形在股票預測／排序任務上的應用與限制.....	6

第三章 實驗設計.....	8
3.1 資料來源與預處理.....	8
3.1.1 資料來源.....	8
3.1.2 資料預處理.....	9
3.1.3 資料集劃分.....	10
3.2 特徵工程與圖結構.....	10
3.2.1 特徵選取與分類.....	10
3.2.2 圖結構設計與建構流程.....	11
3.3 模型設計.....	11
3.3.1 LSTM 基準模型.....	11
3.3.2 DMFM 模型架構 (Wei et al. 2022)	12
3.4 損失函數.....	13
3.4.1 總損失函數.....	13
3.5 評估指標.....	13
3.5.1 預測準確度指標.....	13
3.5.2 投資組合績效指標.....	14
3.5.3 基準比較.....	14
3.5.4 評估流程.....	14
第四章 實驗結果.....	16
4.1 模型對比.....	16
4.2 投組績效驗證.....	16

4.3 特徵重要性排名.....	16
第五章 結論.....	17
5.1 主要發現.....	17
5.2 與既有研究的對比.....	17
5.3 模型限制.....	17
5.4 實踐應用與未來方向.....	17
參考文獻.....	18



圖目錄

圖 1 LSTM 單元的資訊流 (Forget / Update / Output)。其中 x_t 為當期輸入,
 h_{t-1} 為前期隱狀態 (hidden state), c_{t-1} 為前期記憶狀態 (cell state)。

4



表目錄



第一章、緒論

1.1 研究背景

(此處撰寫研究背景內容)

1.2 研究問題

(此處撰寫研究問題內容)

1.3 研究方法與貢獻

(此處撰寫研究方法與貢獻內容)

1.4 論文架構

本論文共分為五章，各章內容如下：

第一章為緒論，說明研究背景、研究問題、研究方法與貢獻，以及論文架構。

第二章為文獻回顧，探討技術指標與特徵工程、LSTM/RNN 方法、圖神經網路基礎，以及 GAT 在股票預測的應用。

第三章為實驗設計，介紹資料來源與預處理、特徵工程與圖結構、模型設計（包含 LSTM、GAT、DMFM 模型）、損失函數，以及評估指標。

第四章為實驗結果，呈現模型對比、投組績效驗證，以及特徵重要性排名。

第五章為結論，總結主要發現、與既有研究的對比、模型限制，以及實踐應用與未來方向。



第二章、文獻回顧

本章依序回顧：(1) 技術指標如何轉化為深度學習可用之特徵表示，(2) LSTM 等時間序列模型在金融預測中的典型做法與延伸，(3) 圖神經網路的基本概念與代表性架構，(4) GAT 及其變形在股票預測／排序任務上的應用與限制，並據此銜接本研究後續以多因子與圖注意力為核心之模型設計與實驗流程。

2.1 技術指標如何轉化為深度學習可用之特徵表示

技術指標 (Technical Indicators, TIs) 以歷史價格與成交量為基礎，將市場的趨勢、動能與波動等訊號轉換為可計算的量化特徵，長期被用於股票預測任務的特徵工程。當指標種類擴張時，特徵集合往往同時伴隨高度相關、冗餘與尺度不一致，使模型訓練成本上升，並可能影響泛化能力與穩健性。

為回應上述挑戰，研究焦點逐步由「是否使用技術指標」轉向「如何將技術指標組織為深度學習可有效吸收的特徵表示」。Agrawal 等人以技術指標作為深度學習模型的輸入，並在股價預測任務中強調多指標組合能提供更完整的市場訊號。[1] Agrawal 等人亦提出以最佳化的深度學習架構搭配技術指標的預測流程，指出在輸入維度增加時，指標集合的挑選與組織方式將直接影響模型是否能有效吸收訊號並降低冗餘干擾。[2] 此外，Li 與 Bastos 以系統性綜述方式整理「技術分析＋深度學習」在股市預測的主要設計與趨勢，並指出「如何識別最優指標集」仍是領域內的重要議題。[3]

總結而言，技術指標在深度學習框架中的角色可被視為「可學習特徵空間的原料」：研究重點不僅在於指標本身，而在於如何以更合適的表示方式降低冗餘並保留有效訊

號，進而提升後續預測任務的可學習性與穩定性。

2.2 LSTM 等時間序列模型在金融預測中的典型做法與延伸

時間序列模型在金融預測中主要利用價格與特徵序列的時間依賴性，學習由過去資訊推估未來表現。長短期記憶網路（Long Short-Term Memory, LSTM）透過閘門（gates）機制控制資訊流動，能緩解長序列學習的梯度消失（vanishing gradients）問題，因此成為金融時間序列建模的代表性方法之一。

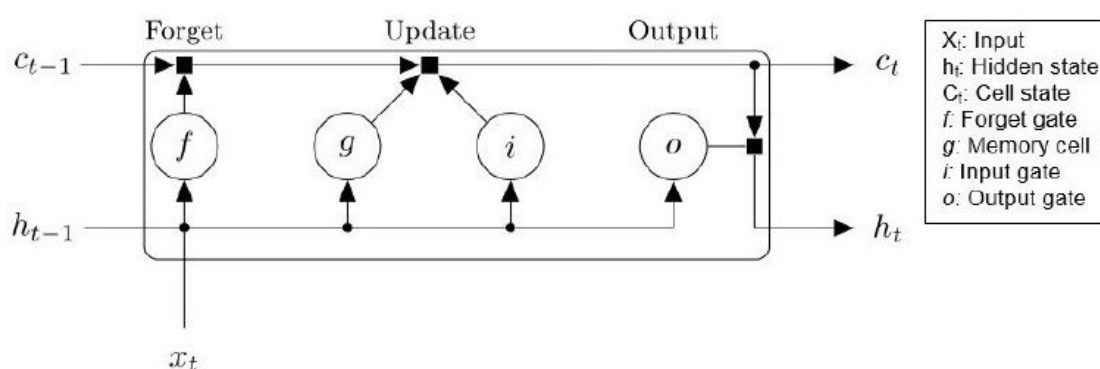


圖 1: LSTM 單元的資訊流 (Forget / Update / Output)。其中 x_t 為當期輸入， h_{t-1} 為前一期隱狀態 (hidden state)， c_{t-1} 為前一期記憶狀態 (cell state)。

如圖 1 所示，LSTM 會沿著記憶狀態 (cell state) 主幹 $c_{t-1} \rightarrow c_t$ 保留長期資訊，並透過三個閘門控制「遺忘 (Forget)」、「更新 (Update)」與「輸出 (Output)」：(1) 遺忘閘門 f_t 決定保留多少過去記憶 c_{t-1} ；(2) 更新步驟由輸入閘門 i_t 與候選記憶 g_t （圖中 memory cell）共同決定要寫入多少新資訊；(3) 輸出閘門 o_t 決定由當期記憶 c_t 產生多少輸出到

隱狀態 h_t 。對應的計算可寫為：

$$\begin{aligned}f_t &= \sigma(W_f[h_{t-1}, x_t] + b_f), \\i_t &= \sigma(W_i[h_{t-1}, x_t] + b_i), \\g_t &= \tanh(W_g[h_{t-1}, x_t] + b_g), \\c_t &= f_t \odot c_{t-1} + i_t \odot g_t, \\o_t &= \sigma(W_o[h_{t-1}, x_t] + b_o), \\h_t &= o_t \odot \tanh(c_t),\end{aligned}\tag{2.1}$$

其中 $\sigma(\cdot)$ 為 sigmoid 函數、 $\tanh(\cdot)$ 為雙曲正切函數， \odot 表示逐元素相乘 (element-wise multiplication)。圖中的方形節點可視為逐元素乘法與加總的運算節點，對應到 $f_t \odot c_{t-1}$ 與 $i_t \odot g_t$ 兩條路徑匯入 c_t 的更新。

在實務與研究中，LSTM 的延伸方向常包含多目標預測、結合注意力機制 (attention mechanism) 與去噪／重加權策略，以及高頻資料下的深層序列建模。Zaheer 等人設計多參數預測架構以同時預測不同價格維度，並比較不同深度模型配置在特定資料規模下的表現差異。[4] Qiu 等人將注意力機制引入 LSTM 架構，以在時間維度上動態調整特徵權重，強化模型在金融資料高雜訊情境下的預測能力。[5] 在高頻 (例如 5 分 K) 資料情境下，鄭邦廷以疊層式 LSTM (Stacked LSTM) 捕捉更複雜的非線性時間依賴，用於買賣點預測。[6] 此外，廖俊翔透過自相關分析與特徵篩選納入跨市場外部特徵，並展示外部訊號在一定程度上能降低預測誤差。[7]

整體而言，時間序列方法能有效吸收單一資產 (或單一特徵集合) 的歷史資訊，但其多數設計仍以「序列本身」為主要訊號來源，較難直接刻畫股票之間的結構性關係與共通影響；因此後續研究開始引入圖結構以建模市場關係。

2.3 圖神經網路的基本概念與代表性架構

圖神經網路 (Graph Neural Networks, GNNs) 以圖作為基本資料結構，透過節點 (node) 與邊 (edge) 描述實體及其關係，並以訊息傳遞 (message passing) 機制聚合鄰居資訊，學得具備拓撲語意的節點表示。Wu 等人對 GNN 架構進行系統性整理，並區分頻域 (spectral-based) 與空域 (spatial-based) 圖卷積之主要差異，同時歸納多類代表性 GNN 架構族群。[8]

在金融市場中，股票之間存在產業層級與市場層級的共同因子影響，亦可能呈現共動性、傳染效應與結構性相依關係。以圖結構建模股票關係，可使模型同時利用「個股特徵」與「關係拓撲」來提升截面預測或排序任務的表現，亦為後續在模型中引入中性化或分離共通影響提供方法基礎。

2.4 GAT 及其變形在股票預測／排序任務上的應用與限制

圖注意力網路 (Graph Attention Network, GAT) 在鄰居聚合框架中引入注意力機制，使模型可對不同鄰居節點賦予不同權重，提升在異質或噪音關係下的表徵能力與可解釋性。以注意力係數為例，其形式可寫為：

$$\alpha_{ij} = \text{softmax}_j \left(\text{LeakyReLU} \left(a^T [W h_i \parallel W h_j] \right) \right), \quad (2.2)$$


其中 h_i 為節點表示， α_{ij} 代表節點 i 對鄰居 j 的注意力權重。

在股票預測任務中，GAT 類方法的效能高度依賴圖結構建構方式與關係訊號品質。Huang 等人提出多層級圖注意力模型 (ML-GAT)，以分層注意力機制分別處理節點狀態與關係類型，使模型能在多來源關係下更細緻地擷取有效訊號。[9] Song 等人以股票價格與股票關係資訊進行圖聚合式排序預測，並討論關係資訊設計對截面排序表現的影

響。[10] 當市場關係稀疏或不完整時，Cheng 等人提出多特徵圖注意力網路，透過整合多面向特徵訊號來提升股票預測能力。[11]

然而，GAT 類方法仍可能面臨下列限制：其一，注意力權重在噪音邊存在時可能分散，增加過擬合風險；其二，圖建構規則、關係來源與連邊密度高度敏感，使模型可轉移性與穩健性需要透過更嚴謹的實證評估驗證；其三，靜態圖難以全面反映關係隨時間變動的特性，可能降低模型對市場結構變化的敏感度。

基於上述研究脈絡，Wei 等人提出以深度多因子模型結合圖注意力的框架，並透過分離產業與全市場層級影響來提升因子信號的可用性與穩健性。[12] 本研究將沿用此一方向，在後續方法設計中以多層級關係建模與中性化概念為核心，並以 IC / ICIR 等指標作為實證評估依據，以對齊第三章所述之實驗設計與評估流程。



第三章、實驗設計

本章詳細介紹實驗的完整設計，包含資料來源與預處理、特徵工程與圖結構建構、模型架構設計等。實驗旨在驗證 Deep Multi-Factor Model (DMFM) 在台灣股票市場預測的有效性，並與時間序列基準模型進行對比分析。

3.1 資料來源與預處理

本研究採用單一日頻股票資料 CSV 檔作為輸入資料，資料包含每日價格與成交資訊，並同時內含產業分類欄位以利建構產業圖。程式支援中英文欄位對照，最少需具備日期、股票代碼與收盤價欄位，其餘欄位（開高低價、成交量/成交值、市值、流通股數、PB/PS 等）作為因子特徵使用。資料期間由參數 `start_date` 與 `end_date` 指定，並以交易日序列為主軸建立時間索引。若資料來源為 TEJ/TSE 等第三方資料庫，請在此節補充實際來源、授權或取得方式。【待補：資料來源、時間區間與股池說明】

3.1.1 資料來源

本研究使用【待補：資料來源名稱】之台灣股票市場日頻資料。資料表至少包含以下欄位：日期、股票代碼、收盤價；其餘可選欄位包含開高低價、成交量、成交值、市值、流通股數、PB/PS 與產業分類欄位（如 TEJ 產業名稱/代碼）。為確保可重現性，程式內已定義中英文欄位映射，當 CSV 欄位名稱不同時仍可正確辨識。

3.1.2 資料預處理

資料預處理是確保模型訓練品質的關鍵步驟，本研究採用的預處理流程如演算法 1 所示。

Algorithm 1 資料預處理流程

- 1: 讀取原始股票資料 (OHLCV, 成交量/成交值, 估值指標, 產業分類)
 - 2: 依股票代碼與日期排序, 數值欄位轉為數值型態
 - 3: 計算標籤: $y_t = \frac{P_{t+k} - P_t}{P_t}$ # k 日未來報酬率
 - 4: 建構產業圖鄰接矩陣 E_{ind}
 - 5: 建構全市場圖鄰接矩陣 E_{uni}
 - 6: 建立特徵張量 $F^t \in \mathbb{R}^{T \times N \times F}$ 與標籤張量 $y^t \in \mathbb{R}^{T \times N}$
 - 7: 以 0 取代特徵中的 NaN/Inf, 標籤 NaN 保留並以 mask 排除
 - 8: 特徵標準化由模型內部的 BatchNorm 完成
-

缺失值處理: 本研究不對缺失值進行插補。特徵層面, 所有 NaN/Inf 以 0 取代 (以保持張量完整性); 標籤層面, NaN 標籤在訓練與評估時以有效樣本 mask 排除, 使模型僅學習可觀測資料。此作法可避免以非實際市場資訊填補所造成的估計偏誤。

特徵標準化: 資料前處理階段不進行截面標準化, 特徵保留原始尺度。模型端在輸入層使用 **Batch Normalization** 進行正規化:

$$x_{normalized} = \frac{x - \mu_{batch}}{\sqrt{\sigma_{batch}^2 + \epsilon}} \quad (3.1)$$

其中 μ_{batch} 與 σ_{batch}^2 為當前 mini-batch 的均值與變異數, ϵ 為數值穩定項 (通常設為 10^{-5})。

此設計具有以下優勢:

- **動態標準化:** 每個 batch 獨立計算統計量, 適應市場環境變化
- **訓練穩定性:** BatchNorm 有助於梯度流動, 加速收斂
- **正則化效果:** 訓練時的 mini-batch 隨機性提供額外正則化

- **等價性:** BatchNorm 在金融時間序列建模中可視為截面標準化的近似

標籤定義: 標籤定義為未來 k 日報酬率，公式如下：

$$y_t = \frac{P_{t+k} - P_t}{P_t} \quad (3.2)$$

其中 P_t 為時間 t 的收盤價， k 為預測視窗 (預設 $k = 5$)。此定義屬於 forward return，避免使用當期或過去資料洩漏未來資訊。

3.1.3 資料集劃分

本研究採用時間序列切分，避免未來資訊洩漏。資料以時間順序切分為訓練集與測試集，預設比例為 80%:20% (前 80% 為訓練、後 20% 為測試)。訓練過程採用 early stopping，並以測試期 ICIR 作為模型保存依據。若需更嚴謹實驗，可進一步拆出 validation set 以獨立調參。【可選補充】

3.2 特徵工程與圖結構

3.2.1 特徵選取與分類

本研究特徵涵蓋多種技術面與統計面訊號，主要可分為：

- **報酬與動能特徵:** 1/3/5/10/20 日報酬、短長動能差 (ret10-ret1、ret20-ret1)。
- **趨勢特徵:** 價格相對移動平均 (5/10/20/60 日)、價格相對近 20 日高低點位置。
- **波動與風險特徵:** 5/10/20/60 日報酬標準差、ATR、最大回撤 (20 日)、beta 與特質波動。
- **量能特徵:** 成交量相對均值、上/下漲日平均量。

- **技術指標:** RSI、KD、MACD。
- **統計特徵:** 偏度、峰度、價格 z-score。
- **流動性與估值:** Amihud illiquidity、PB、PS。

上述特徵由單一 CSV 自動衍生，不需額外外部因子資料。

3.2.2 圖結構設計與建構流程

產業圖 (Industry Graph): 產業圖以「同產業股票完全連結」為設計原則，將屬於同一產業的股票視為相互連結，並為每檔股票加入自環。此設計能捕捉同產業內的共通訊號與產業影響。

全市場圖 (Universe Graph): 全市場圖採完全圖設計，所有股票相互連結並包含自環，用以表徵跨產業的市場共同因子影響。此設計對應 DMFM 論文中的 Universe-level 關係，能強化市場共同變動的抽取。

鄰接矩陣表示: 圖結構以 PyG 的 `edge_index` 表示，即 $[2, E]$ 形式之邊索引。實作上先以鄰接矩陣建立連結，再轉換為邊索引格式，以利 GAT 層使用。

建構流程: 由輸入 CSV 讀取產業欄位（如 TEJ 產業名稱/代碼），依股票代碼分組建立產業圖；若缺少產業欄，則預設所有股票屬於同一產業。全市場圖則依股票清單建立完全圖。圖結構與特徵張量一併存入 artifacts，供模型訓練與評估重複使用。

3.3 模型設計

3.3.1 LSTM 基準模型

模型架構: 目前程式碼未包含 LSTM 實作。若需保留此節，建議改為「GATRegressor 基準模型」，或自行補上 LSTM baseline。以下提供兩種處理方式：

- 改寫為 GATRegressor 基準：兩層 GAT + 線性輸出，僅使用產業圖。
- 新增 LSTM baseline：以時間序列特徵輸入 LSTM，再用 MLP 輸出預測。

【待選：採用 GATRegressor 或補上 LSTM baseline】

超參數配置：若採 GATRegressor 基準，建議使用與 DMFM 相同的 hidden_dim、heads 與 dropout，以確保可比性；若採 LSTM baseline，則需補充 LSTM 的 hidden size、層數、dropout 與輸出頭設定。【待補：基準模型超參數】

與 DMFM 的差異：LSTM 基準僅利用時間序列特徵，不顯式建模股票間關係；DMFM 則透過產業圖與全市場圖進行中性化，並以階層式拼接整合多層語境，因此能同時捕捉個股特徵與結構性訊號。【待補：是否保留 LSTM baseline】

3.3.2 DMFM 模型架構 (Wei et al. 2022)

DMFM 以「特徵編碼 → 產業中性化 → 全市場中性化 → 階層式拼接 → 深度因子學習 → 因子注意力」為主要流程。模型在每個交易日 t 對股票截面進行運算，輸出每檔股票的預測因子值。

步驟 1：特徵編碼器：原始特徵 F^t 經過 BatchNorm 進行截面標準化，再以 MLP 編碼為 C^t (hidden_dim 維度)，作為原始股票語境表示。

步驟 2：產業中性化：以產業圖為圖結構進行 GAT 運算，得到產業影響 H_I^t 。產業中性特徵定義為： $C_I^t = C^t - H_I^t$ ，藉此移除產業共通影響。

步驟 3：全市場中性化：在產業中性特徵 C_I^t 上，再以全市場圖進行 GAT 運算得到 H_U^t 。全市場中性特徵定義為： $C_U^t = C_I^t - H_U^t$ ，用以移除市場共同影響。

步驟 4：階層式特徵拼接：將三層特徵拼接形成階層表示： $H^t = [C^t \parallel C_I^t \parallel C_U^t]$ 。此設計保留原始語境與兩層中性化資訊，提升模型表達力。

步驟 5：深度因子學習：拼接後的階層特徵輸入 MLP decoder，輸出深度因子 f^t (每檔股票 1 個數值)，作為預測信號。

步驟 6：因子注意力模組：模型同時對原始特徵學習注意力權重，計算 $\hat{f}^t = F^t \odot a^t$ ，用以估計「哪些特徵驅動因子輸出」，並作為解釋與監督項。

超參數配置：預設配置如下：hidden_dim=64、heads=2、dropout=0.1、epochs=200、learning rate=1e-4、weight decay=0.01、lambda_attn=0.1、lambda_ic=1.0、patience=30。

3.4 損失函數

3.4.1 總損失函數

本研究使用 DMFM 對應之損失：

$$L = \lambda_{attn} \cdot \|f - \hat{f}\| + \lambda_{IC} \cdot (1 - IC) - \lambda_b \cdot b \quad (3.3)$$

其中 $\|f - \hat{f}\|$ 代表注意力估計誤差； IC 為資訊係數； b 為截面回歸得到的因子收益。程式中 λ_b 固定為 0.01，以降低因子收益項之不穩定性。

Information Coefficient (IC)：IC 以 Pearson correlation 計算，基於每個交易日的截面預測與真實報酬，衡量預測排序的有效性。

優化器設定：使用 AdamW 優化器，並加入 weight decay 以抑制過度擬合。

3.5 評估指標

3.5.1 預測準確度指標

IC / Daily IC / ICIR：IC 為整體樣本的 Pearson correlation；Daily IC 為每交易日 IC 的平均值；ICIR 定義為 IC 平均值除以 IC 標準差，用以衡量資訊係數的穩定性。

產業中性 IC：【待補：若有計算產業中性 IC，請補充定義與計算方式；若未使用，可

刪此項。】

方向準確率：方向準確率定義為預測方向與真實方向一致的比例，用以衡量模型對漲跌方向的掌握程度。

誤差指標：以全部測試樣本誤差衡量預測偏差，包含 MSE、RMSE 與 MAE。

3.5.2 投資組合績效指標

年化報酬率：策略以每次再平衡取預測分數最高的 top_pct 股票做多，計算該截面平均報酬作為策略報酬，並依再平衡頻率換算年化報酬率。

Sharpe Ratio：Sharpe Ratio 定義為平均報酬除以波動後乘上年化因子，用於衡量風險調整後報酬。

勝率：勝率為正報酬期間比例，用於衡量策略穩定性。

最大回撤：程式中未計算最大回撤，若需納入，可額外補實作或引用後處理結果。【待補：是否加入最大回撤】

3.5.3 基準比較

天真基準：天真基準設定所有股票預測值為 0，計算 MSE/RMSE/MAE，並與模型結果比較改善幅度。

台灣 50 ETF 基準：使用 0050 報酬資料計算 forward- k 日報酬，與策略累積報酬比較。

3.5.4 評估流程

流程為：

- 載入 artifacts 與模型權重。
- 對訓練期與測試期分別計算預測指標。

- 產生 Daily IC、方向命中率、預測離散度、IC 分佈與累積報酬等視覺化報告。
- 若為 DMFM，另外輸出注意力權重分佈以進行解釋性分析。



第四章、實驗結果

4.1 模型對比

(此處撰寫模型對比內容)

4.2 投組績效驗證

(此處撰寫投組績效驗證內容)

4.3 特徵重要性排名

(此處撰寫特徵重要性排名內容)



第五章、結論

5.1 主要發現

(此處撰寫主要發現內容)

5.2 與既有研究的對比

(此處撰寫與既有研究的對比內容)

5.3 模型限制

(此處撰寫模型限制內容)

5.4 實踐應用與未來方向

(此處撰寫實踐應用與未來方向內容)

參考文獻

- [1] M. Agrawal, P. K. Shukla, R. Nair, A. Nayyar, and M. Masud, “Stock prediction based on technical indicators using deep learning model,” *Computers, Materials & Continua*, vol. 70, no. 1, pp. 287–304, 2022.
- [2] M. Agrawal, A. U. Khan, and P. K. Shukla, “Stock price prediction using technical indicators: A predictive model using optimal deep learning,” *International Journal of Recent Technology and Engineering (IJRTE)*, vol. 8, no. 2, pp. 2297–2305, 2019.
- [3] A. W. Li and G. S. Bastos, “Stock market forecasting using deep learning and technical analysis: A systematic review,” *IEEE Access*, vol. 8, pp. 185 197–185 215, 2020.
- [4] S. Zaheer, N. Anjum, S. Hussain, A. D. Algarni, J. Iqbal, S. Bourouis, and S. S. Ullah, “A multi parameter forecasting for stock time series data using lstm and deep learning model,” *Mathematics*, vol. 11, no. 3, p. 590, 2023.
- [5] J. Qiu, B. Wang, and C. Zhou, “Forecasting stock prices with long-short term memory neural network based on attention mechanism,” *PLoS ONE*, vol. 15, no. 1, p. e0227222, 2020.
- [6] 鄭邦廷, “基於深度學習與技術分析指標預測股市買賣點,” Master’s thesis, 國立臺灣師範大學機電工程學系, 台北, 台灣, 2023, stock buy and sell points prediction based on deep learning and technical analysis indicators.

- [7] 廖俊翔, “應用深度學習結合自相關分析優化股票預測模型,” Master’s thesis, 國立中興大學資訊管理學系, 台中, 台灣, 2022, applying deep learning combined with autocorrelation analysis to optimize stock forecasting model.
- [8] Z. Wu, S. Pan, F. Chen, G. Long, C. Zhang, and P. S. Yu, “A comprehensive survey on graph neural networks,” *IEEE Transactions on Neural Networks and Learning Systems*, vol. 31, no. 1, pp. 4–24, 2020.
- [9] K. Huang, X. Li, F. Liu, X. Yang, and W. Yu, “Ml-gat: A multilevel graph attention model for stock prediction,” *IEEE Access*, vol. 10, pp. 85 472–85 483, 2022.
- [10] G. Song, T. Zhao, S. Wang, H. Wang, and X. Li, “Stock ranking prediction using a graph aggregation network based on stock price and stock relationship information,” *Information Sciences*, vol. 643, p. 119236, 2023.
- [11] L. Cheng, J. Wen, and Y. Wang, “Stock prediction model based on multi-feature graph attention network,” *Nanjing University of Aeronautics and Astronautics (Manuscript)*, 2024, manuscript.
- [12] Z. Wei, B. Dai, and D. Lin, “Factor investing with a deep multi-factor model,” *arXiv preprint*, 2022, under Review.